

五、从本地到云端——构建具备专业知识的AI学习助手

任务一：本地“小脑”——运行本地开源模型

完成情况：

能正常加载模型并输出问题的回答

```
2025-10-03 10:01:05.516381: I tensorflow/core/util/port.cc:113] oneDNN custom operations are on. You may see slightly different numerical results due to floating-point precision loss when using older TensorFlow versions.
WARNING:tensorflow:From D:\anaconda\envs\pytorch_env\Lib\site-packages\keras\src\losses.py:2976: The name tf.losses.sparse_softmax_cross_entropy is deprecated. Please use tf.nn.sparse_softmax_cross_entropy_with_logits instead.

问题：请简单介绍一下牛顿第三定律。
回答：请简单介绍一下牛顿第三定律。 牛顿第三定律，即作用与反作用原理，是经典力学中的一个基本定理，它描述了物体间的相互作用关系。其内容为：对于任何一个力的施加者而言，都有一个大小相等、方向相反的反作用力。具体来说，假设A对B施加了一个力F，那么B也会以同样大小但方向相反的力F'对A产生反作用力。这个反作用力就是作用在A上的力F的反作用力F'，两者大小相等、方向相反、作用点和作用线都位于同一直线上。

这个原理说明了任何物体之间都存在相互作用力，而且这种作用力总是成对出现的，其中一方受到的力等于另一方给它的力。这一原理不仅适用于宏观物体，也适用于微观粒子，如电子和光子等，在量子力学中也有应用。

理解牛顿第三定律不仅是物理计算的基础，也是许多科学领域（包括工程学、天文学、航天学等）中解决复杂问题的关键。

进程已结束，退出代码为 0
```

硬件配置：

操作系统：Windows10
处理器: Intel64 Family 6 Model 170 Stepping 4, GenuineIntel
CPU核心数：18
无GPU🥹

本地模型速度：

模型加载时间约10秒，文本生成时间约20秒，第一次下载模型耗时约8分钟

遇到的问题

- 有时候会出现一句话只输出了一半：提高max_new_tokens的值（初始为150）：改为300后没有再出现问题（改为200时偶尔输出不完）
- 一直有两行警告，不影响输出结果，但是看着有点难受

```
2025-10-02 22:19:16.197665: I tensorflow/core/util/port.cc:113] oneDNN custom operations are on. You may see slightly different numerical results due to floating-point precision loss when using older TensorFlow versions.
WARNING:tensorflow:From D:\anaconda\envs\pytorch_env\Lib\site-packages\keras\src\losses.py:2976: The name tf.losses.sparse_softmax_cross_entropy is deprecated. Please use tf.nn.sparse_softmax_cross_entropy_with_logits instead.
```

（暂未解决）

一些思考：

设置随机采样，使得同样的代码，同样的问题跑两遍得到的结果不完全一样。

```
do_sample=True,      # 启用随机采样
temperature=0.7,     # 引入随机性
top_p=0.95,          # 增加多样性
```

学习笔记

- 代码结构：设置模型路径、加载分词器、加载模型、准备提示词并进行推理、输出结果

- 一些知识

分词器：先将句子拆分为小单元，再将它们转化为数字编码，最后将模型输出的数字转化为文本

max_new_tokens：控制生成文本的最大采样长度，token即模型中处理的最小语义单位，用于将文本分割为模型可计算的基本单元。

do_sample：采样策略，true则为按概率分布随机采样，false则为贪婪采样，即选择当下概率最高的词。贪婪采样每次的结果确定，速度较快，但多样性低

temperature：控制生成的随机性与创造性，接近于0时会放大原始的概率差异，结果更保守准确，反之使概率更加接近，创造力更强，但可能不连贯，一般选择在0.5-0.8之间

top_p：核采样，先将概率从高到低排序，再从累积概率达到p的词汇中进行选择，从而调整候选词数量。

pad_token_id：填充标记ID，用来统一序列长度的特殊标记，代码中使用

`pad_token_id=tokenizer.eos_token_id`，即用结束标记来充当填充标记，避免输出无意义标记或无关内容

repetition_penalty：重复惩罚，=1.0即没有惩罚，1.5以上为强力惩罚，几乎杜绝重复但可能影响连续性，代码中使用1.1，轻微惩罚

任务二：连接云端“超脑”——调用API

完成情况

能正常运行并输出结果

```
D:\anaconda\envs\pytorch_env\python.exe D:\kaifangyuanzi\LLM\API.py
回答内容：
牛顿第三定律，也称为**作用力与反作用力定律**，是经典力学中的基本定律之一。它的内容可以简单表述为：

> **当一个物体对另一个物体施加力（作用力）时，第二个物体也会同时对第一个物体施加一个大小相等、方向相反的力（反作用力）。**

换句话说：**每一个作用力都有一个大小相等、方向相反的反作用力。**

用公式表示就是：
** $F_{12} = -F_{21}$ **
其中  $F_{12}$  表示物体1对物体2的作用力， $F_{21}$  表示物体2对物体1的反作用力。

### 举例说明：
- 当你站在地面上时，你的脚对地面施加一个向下的力（由于重力），同时地面也对你施加一个向上的支持力，这两个力大小相等、方向相反。
- 火箭升空时，向下喷出气体，气体对火箭产生一个向上的反作用力，推动火箭上升。

### 注意：
- 作用力和反作用力**总是成对出现**，且作用在**不同的物体上**，因此它们不会相互抵消。
- 它们**性质相同**，比如都是引力、弹力或摩擦力等。

牛顿第三定律揭示了力的相互性，是理解物体间相互作用的基础。

进程已结束，退出代码为 0
```

对本地模型和云端API输出质量的对比分析

- 本地模型：输出内容较单一，回答较简略
- 云端API：输出内容丰富，有举例说明，公式表达和注意事项等，更加详细

对本地模型和云端API速度的对比分析

- 本地模型：运行总时长约30秒
- 云端API：生成答案约5秒

学习笔记

- 代码结构：定义函数、调用千问3大模型、设置参数、处理响应结果、运行
- 一些知识：

配置环境

```
C:\Users\鲍心妍>setx DASHSCOPE_API_KEY "sk-6d76eaa9a38e468696b04eb9319c95ee"
成功：指定的值已得到保存。
```

dashscope：阿里云DashScope SDK，用于调用通义千问等大模型
top_k:固定数量，即选概率值最高的前k个词
HTTP状态码：表示服务器对HTTP请求的处理结果， `response.status_code == 200`即HTTP状态码为200，请求成功

任务三：框架赋能——使用LangChain构建专业知识库问答系统

完成情况

能正常输出结果

```
问题：狭义相对论和广义相对论有什么区别？

回答：
狭义相对论和广义相对论是爱因斯坦创立的关于时空与引力的两个重要理论，它们研究对象、适用范围、时空背景以及发展动因等方面存在根本区别。具体区别如下：

1. **是否涉及引力（弯曲时空）**：
- **狭义相对论**只处理没有引力作用或引力可以忽略的情况。它适用于惯性参考系，即匀速直线运动或静止的观察者所处的参考系。
- **广义相对论**则将引力纳入理论框架，用来描述引力作用下的物理现象。它认为引力不是一种传统意义上的力，而是由质量和能量引起的时空弯曲的表现。

2. **时空结构的不同**：
- 在**狭义相对论**中，背景时空是**平直的四维闵氏时空（Minkowski spacetime）**，其几何结构由闵可夫斯基度规描述，时空的曲率张量为零，意味着时空没有弯曲。
- 而在**广义相对论**中，时空是**弯曲的**，其几何结构由爱因斯坦场方程决定，曲率张量不为零，反映了物质和能量如何导致时空的弯曲。

3. **参考系的适用范围**：
- **狭义相对论**仅限于**惯性参考系**之间的变换，使用洛伦兹变换来联系不同惯性系中的物理测量结果。
- **广义相对论**推广到了**任意参考系**，包括非惯性系（如加速参考系），并通过协变原理确保物理定律在所有坐标系下形式不变。

4. **理论发展的起源与动因不同**：
- **狭义相对论**的提出源于经典物理学内部的矛盾（如麦克斯韦电磁理论与牛顿力学在参考系变换上的冲突）、迈克耳孙-莫雷实验等新实验结果的推动，属于“实验引导理论”的典型例子。
- 相比之下，**广义相对论**更多是由理论自身的发展需求驱动的，是在狭义相对论基础上对引力问题进行逻辑扩展的结果。它在很大程度上是“理论走在实验前面”的典范，在提出初期缺乏直接的实验证据支持，因此被誉为“理论物理学的大胆飞跃”。

5. **物理观念的深化**：
- 狭义相对论引入了“同时的相对性”、“四维时空”等新概念，改变了人们对时间与空间独立性的传统认识。
- 广义相对论进一步提出了“弯曲时空”的概念，将引力解释为时空几何的属性，实现了引力与几何的统一，是对自然界更深层次规律的揭示。

综上所述，狭义相对论与广义相对论的主要区别在于：前者是在平直时空中、不考虑引力作用的相对性理论，适用于惯性系；后者则是包含引力、以弯曲时空为基础、适用于一切参考系的更普遍理论。可以说，广义相对论是狭义相对论的推广和深化。

进程已结束，退出代码为 0
```

遇到的问题

- 第一次下载模型并输出时是正常的，但是第二次再运行的时候仍进行网络检查且一直网络连接超时，无法正常输出
解决方法：手动指定模型缓存路径，强制使用已经下载好的模型而避免网络检查。
原代码：

```
embeddings=HuggingFaceEmbeddings(model_name="BAAI/bge-small-zh-v1.5")
```

改后代码：

```
embeddings = HuggingFaceEmbeddings(  
    model_name="BAAI/bge-small-zh-v1.5",  
    cache_folder="C:/Users/鲍心妍/.cache/huggingface/hub",  
    model_kwargs={'local_files_only': True}  
)
```

- 和任务——一样的小问题：一直有两行警告，不影响输出结果，但是看着有点难受（警告和任务一相同）

学习笔记

- 代码结构：导入、配置、封装、数据处理、检索、定义模板、定义rag流程函数、测试
- 一些知识：

分片：将文本分成多个片段

embedding：把文本转化为向量得到过程

向量数据库：用于查询和存储向量的数据库（原始文本和向量都存在向量数据库里）

索引：包含将文本通过embedding转化为向量以及存储到向量数据库的过程

召回：搜索与用户问题相关片段的过程（计算向量相似度）

重排：重新排序（与召回相似，但用的文本相似度计算逻辑不同），进一步缩小范围

计算文本相似度方法：*a. 向量相似度*：成本低，耗时短，准确率低，一般用于召回阶段。*b. cross-encoder*：成本高，耗时长，准确率高，一般用于重排阶段。