

Transformer —— “Attention Is All You Need” 论文精读与实践

任务一：理论问答

1. 在 Transformer 出现之前，主流的序列模型（如 RNN, LSTM 等）存在什么关键的局限性？

- 顺序依赖、难以并行化：RNN 需要按时间步顺序处理序列。这种固有的顺序性导致训练速度慢，尤其是在处理长序列时。
- 长程依赖：处理非常长的序列时，信息在长距离传递中会逐渐衰减或丢失。模型难以记住序列开头的重要信息。

2. 什么是注意力机制？Transformer 架构是如何仅通过注意力机制来解决上述局限性的？

- 注意力机制是一种模拟人类认知中“关注重点”的机制。核心思想：模型可以根据相关性为不同元素分配不同的权重。重要的元素获得高权重，对当前输出的贡献更大。
- a. 解决并行化问题：Transformer 摒弃了循环结构，注意力机制允许模型同时处理序列中的所有位置。对于序列中的每一个词，它都可以直接与其他词进行计算，从而实现了完全的并行化，极大地加快了训练速度。
- b. 解决长程依赖问题：在自注意力中，任意两个位置的交互都是直接的，只需要一次矩阵运算。这意味着序列开头和结尾的词可以直接建立联系，彻底解决了长程依赖问题。
- c. 解决信息瓶颈：每个词的表示都是通过“关注”所有其他词的表示并加权求和得到的，而不是被压缩到一个固定的隐藏状态中。这为模型提供了更丰富、更全局的上下文信息。

3. 请描述论文中提出的缩放点积注意力（Scaled Dot-Product Attention）的计算全过程。公式：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

中的 Q, K, V 分别代表什么？为什么需要除以 $\sqrt{d_k}$ 进行缩放？

- 过程：输入后，先对每一个 query 和 key 的转置做点积，然后把它作为相似度（点积值越大，两个向量的相似度越高，点积为 0，两向量正交，没有相似度），再除以向量的长度进行缩放，再通过每一行使用 softmax 转化为概率分布，得到权重
 - Q: query, 代表当前的需求和意图
 - K: key, 资料的核心标识
 - V: value, 最终想获取的实质信息
 - 除以 $\sqrt{d_k}$ 缩放原因： d_k 是向量的长度，即模长，当 d_k 较大时，点积的值也会比较大，从而导致相对差距变大，再经过 softmax 后，最大的值会更靠近于 1，而其他值会更加靠近于 0，从而导致最后计算的梯度较小，可能导致梯度消失，除以 $\sqrt{d_k}$ 可以将点积的数值控制在一个合理的范围内，确保 softmax 函数处在梯度敏感的区域，且防止点积过大（可以看做向量标准化？）
- ### 4. 什么是多头注意力机制（Multi-Head Attention）？它相比于只使用单个注意力机制有什么优势？论文中是如何将多个头的输出结果合并的？

- 多头注意力机制是将缩放点积注意力过程并行地执行多次
方法：将输入的 Q, K, V 通过不同的线性投影层，分别投影到 h 个不同的、维度更小的子空间。再在每个子空间上独立地执行缩放点积注意力计算，再将 h 个头得到的输出矩阵拼接起来。最后再通过一个线性投影层，将拼接后的矩阵映射回期望的输出维度。

- 优势：a. 不同的头可以学习到不同的注意力模式。
b. 将注意力机制在多个不同的投影子空间中运行，为模型提供了更强大的联合表征能力
- 合并方法：拼接。将所有头的输出矩阵在特征维度上拼接起来，然后通过一个可学习的权重矩阵 W^O 进行线性变换，得到最终的输出。

5. 请简要描述位置编码（Positional Encoding）的原理和必要性，并解释为什么选择使用正弦和余弦函数。

- 原理：位置编码是一个与词嵌入维度相同的向量，它直接与词的嵌入向量相加，作为 Encoder 和 Decoder 的输入。使得模型在处理每个词时，能同时获得词的语义信息和位置信息。
- 必要性：自注意力机制中，打乱输入序列的顺序，输出的集合不变，只是顺序被打乱。因此，必须向模型注入关于词汇在序列中位置的信息。
- 选用正余弦函数原因：
 - a. 正余弦函数便于描述相对位置
 - b. 正余弦函数是周期性的，且有界，有较好的外推性，不会出现数值爆炸。
 - c. 不需要额外参数的学习，计算高效

6. 简述 Transformer 的 Encoder 和 Decoder 各自的结构和功能。

- encoder：a. 结构：由 N 个相同的层堆叠而成，每一层包含两个子层：多头自注意力机制和前馈神经网络，每个子层周围都有一个残差连接，后接层归一化。
b. 功能：处理输入序列，将其转换为一个包含上下文信息的中间表示或记忆，即捕获输入序列中的元素及其复杂关系。
- decoder：a. 结构：由 N 个完全相同的层堆叠而成，每一层包含三个子层：带掩码的多头自注意力机制，多头注意力机制和前馈神经网络。且每个子层都有残差连接和层归一化。
b. 功能：以自回归的方式工作，根据之前生成的输出词和编码器提供的输入序列表示，生成下一个输出词。

7. Decoder 中同时存在多头掩码注意力机制（Masked Multi-Head Attention）和不带掩码的多头注意力机制，它们有什么区别？为什么 Decoder 需要两种注意力机制？

- 带掩码：在进行 t 时刻的计算时，使 t 时刻以后的输入在参数更新时不起效果
- 不带掩码：可以看到全部的输入
- 原因：为了保证训练与预测时的行为一致，防止信息泄露，保证自回归生成的有效性。

任务二：数学推导

解答（手写）：

一. x_1 的 Q, K, V 向量

$$Q_1 = x_1 \cdot W_Q = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$K_1 = x_1 \cdot W_K = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 0 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

$$V_1 = x_1 \cdot W_V = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 0 & 2 & 0 \\ 1 & 0 & 3 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix}$$

二. x_2 的 Q, K, V 向量

$$Q_2 = x_2 \cdot W_Q = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$

$$K_2 = x_2 \cdot W_K = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} 0 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}$$

$$V_2 = x_2 \cdot W_V = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} 0 & 2 & 0 \\ 1 & 0 & 3 \\ 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 4 \end{pmatrix}$$

三. Q, K 矩阵

$$Q = \begin{pmatrix} Q_1^T \\ Q_2^T \end{pmatrix} = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \quad K = \begin{pmatrix} K_1^T \\ K_2^T \end{pmatrix} = \begin{pmatrix} 0 & 1 & 2 \\ 2 & 1 & 0 \end{pmatrix}$$

四. 分数矩阵 + 归一化

$$\text{注意力分数: } QK^T = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 0 & 2 \\ 1 & 1 \\ 2 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 4 \\ 3 & 1 \end{pmatrix}$$

$$\text{缩放: } \frac{QK^T}{\sqrt{d_k}} = \frac{QK^T}{\sqrt{3}} = \begin{pmatrix} \frac{2}{\sqrt{3}} & \frac{4}{\sqrt{3}} \\ \frac{3}{\sqrt{3}} & \frac{1}{\sqrt{3}} \end{pmatrix} \approx \begin{pmatrix} 1.155 & 2.309 \\ 1.732 & 0.577 \end{pmatrix}$$

五. softmax 函数

$$\text{第一行: } \left(\frac{e^{1.155}}{e^{1.155} + e^{2.309}}, \frac{e^{2.309}}{e^{1.155} + e^{2.309}} \right) \approx (0.240, 0.760)$$

$$\text{第二行: } \left(\frac{e^{1.732}}{e^{1.732} + e^{0.577}}, \frac{e^{0.577}}{e^{1.732} + e^{0.577}} \right) \approx (0.760, 0.240)$$

$$\text{Attention} = \begin{pmatrix} 0.240 & 0.760 \\ 0.760 & 0.240 \end{pmatrix}$$

六. 自注意力输出

$$V = \begin{pmatrix} V_1^T \\ V_2^T \end{pmatrix} = \begin{pmatrix} 1 & 3 & 0 \\ 1 & 0 & 4 \end{pmatrix}$$

最终输出: $\text{Attention} \cdot V = \begin{pmatrix} 0.240 & 0.760 \\ 0.760 & 0.240 \end{pmatrix} \begin{pmatrix} 1 & 3 & 0 \\ 1 & 0 & 4 \end{pmatrix}$

$$= \begin{pmatrix} 1.000 & 0.720 & 3.040 \\ 1.000 & 2.280 & 0.960 \end{pmatrix}$$

即: $Z_1 = (1.000 \quad 0.720 \quad 3.040)$

$Z_2 = (1.000 \quad 2.280 \quad 0.960)$